

修士論文

大規模言語モデルにおける固有ニューロンの 層分布と語順依存性の解析

2026年2月4日

情報学研究科 データ科学コース 統計知能研究室

修士課程二年 蝶野 元哉


指導教員 下平英寿 教授

背景: 言語固有ニューロン (Kojima et al., 2024)

- LLM(大規模言語モデル)における、
特定の言語の文に一貫して強く反応するニューロン
- モデルの序盤/終盤のTransformer層に偏って分布
- 出力値を固定することで生成される文の言語を制御できる

課題

言語固有ニューロンが反応している具体的な特徴や、
モデル全体の言語能力を構成する上での役割などは十分に解明されていない



本研究の内容

LLMは、序盤層でトークンの埋め込みを抽象度の高い表現に変換し、中間層で推論を行ったのち終盤層で出力先の言語の表現に再変換する (Wendler et al., 2024, Zhao et al., 2024)

→ 以下の仮説を立て、固有ニューロン群の層分布および語順に対する依存性を解析・比較

仮説1: 言語固有ニューロンは、トークン自体のような推論に関わらない特徴に反応している


実験1: 入力トークンをシャッフルした状態で言語固有ニューロンを特定し、元々のニューロン集合と比較

仮説2: 中間層には、意味的な推論に関わる別のニューロン群が存在する

実験2: 文のドメイン(分野)に関する固有ニューロンを特定し、言語固有ニューロンと比較

層ごとの言語固有ニューロンの数(XGLM-564M)

(横軸: 層番号 / 縦軸: ニューロン数)



固有ニューロンの特定 (Kojima et al., 2024)


目的: 単一のカテゴリの文に一貫して強く反応するニューロンの特定

データセット: 各カテゴリ $l \in L$ に対して $N_l = 500$ 文ずつ

テキスト $x_i = \{w_{i,1}, \dots, w_{i,T}\}$ に対するニューロン $m \in M$ の出力平均:

$$z_{m,i} = f(z_{m,i,1}, \dots, z_{m,i,T})$$

f : 平均演算子



固有ニューロンの特定 (2)


注目するカテゴリ: $l_t \in L$ の文にのみ一貫して大きい値を出力するニューロンを調べるため、ニューロン m の出力値 $z_{m,i}$ を用いて l_t の文であることを示すラベル b_i を予測するタスクを設定

データセット: $\{x_i, b_i, z_{m,i}\}_{i=1}^N$, $b_i = \begin{cases} 1 & (x_i \text{ が } l_t \text{ の文}) \\ 0 & (\text{otherwise}) \end{cases}$

分類器 $g(z_{m,i}) = \begin{cases} 1 & (z_{m,i} \geq \tau) \\ 0 & (z_{m,i} < \tau) \end{cases}$

平均適合率(Average Precision)でニューロン m を評価:

$$AP_m = AP(z_m, b) \in [0,1]$$



固有ニューロンの特定（3）


平均適合率: 分類の閾値 τ を変化させた際のPrecision-Recall曲線の下面積

$$\text{Precision} = \frac{TP}{TP + FP}, \text{Recall} = \frac{TP}{TP + FN}$$

TP : 真陽性 ($g(z_{m,i}) = 1, b_i = 1$)の数

FP : 偽陽性 ($g(z_{m,i}) = 1, b_i = 0$)の数

FN : 偽陰性 ($g(z_{m,i}) = 0, b_i = 1$)の数



カテゴリ l_t の文のみに対して $z_{m,i}$ の値が大きければ AP_m が大きくなる

AP_m が上位/下位で k 位以内に位置するニューロンを l_t の固有ニューロンとして特定

実験設定

- ・ 先述の手法で、様々なデータセットに対して固有ニューロンを特定
 - ・ AP_m が上位/下位 $k = 1000$ 個ずつを固有ニューロンとする
- ・ Transformer層ごとの分布、固有ニューロン同士の重複、出力値を固定して生成された文を調べる
- ・ モデルはXGLM, BLOOM, Llama2から計8つを使用
 - ・ 本発表では、赤線で示した3つのモデルでの結果を紹介

モデル	パラメータ数	層数	ニューロン数
XGLM	<u>564M</u>	24	221,184
	1.7B	24	442,368
	2.9B	48	884,376
BLOOM	560M	24	221,184
	<u>1.7B</u>	24	442,368
	3B	30	691,200
Llama2	<u>7B</u>	32	1,359,872
	13B	40	2,129,920

実験に使用したモデルと層・ニューロン数


実験 1: 言語固有ニューロンの語順依存性の解析

目的: 入力トークンのシャッフルにより、言語固有ニューロンの語順依存性を調べる


言語: $L_{\text{lang}} = \{\text{de, en, es, fr, ja, zh}\}$

データセット: PAWS-X (Yang et al., 2019) より各言語に対して500文ずつ

言語固有ニューロンの集合 $M_{l_t}^{\text{lang}}, M_{l_t}^{\text{lang-s}}$ ($l_t \in L_{\text{lang}}$) を取得




$M_{l_t}^{\text{lang}}$: 通常のデータセット



$M_{l_t}^{\text{lang-s}}$: 各文のトークンをランダムにシャッフル

結果1.1: 言語固有ニューロンの層分布とシャッフル前後の重複



固有ニューロンの層ごとの分布(言語ごとの平均)

(横軸: 層番号 / 縦軸: ニューロン数)

	de	en	es	fr	ja	zh
XGLM-564M	80.45	77.10	81.80	76.40	71.30	73.10
BLOOM-1.7B	66.45	80.55	79.65	74.70	69.20	62.45
Llama-2-7B	60.45	50.90	58.50	60.01	26.35	37.10

$M_{l_t}^{lang}$ と $M_{l_t}^{lang.s}$ の重複割合(%)

- ・ 序盤/終盤層に偏って分布
- ・ シャッフルする前後で層分布の傾向は変わらず、 $M_{l_t}^{lang}$ と $M_{l_t}^{lang.s}$ の大部分が重複

結果1.2: 言語固有ニューロンの制御

先行研究の結果

$m \in M_{l_t}^{\text{lang}}$ の出力値を、言語 l_t における出力の中央値で固定すると、空のプロンプトを入力した際に言語 l_t の文が出力される割合が上昇

$$\bar{z}_m = \text{Median}(\{z_m | b = 1\})$$

実験1の結果

$M_{l_t}^{\text{lang-s}}$ を制御した場合も、 $M_{l_t}^{\text{lang}}$ の場合と同等の出力割合

→ 言語固有ニューロンは語順への依存性が低い

トークン自体など、意味や文法に無関係な特徴に反応していると考察

		制御なし	$M_{l_t}^{\text{lang}}$ を制御	$M_{l_t}^{\text{lang-s}}$ を制御
XGLM-564M	de	0.0	100.0	99.0
	en	45.0	94.0	93.0
	es	2.0	92.0	90.0
	fr	1.0	98.0	88.0
	ja	10.0	100.0	100.0
	zh	8.0	98.0	98.0
BLOOM-1.7B	de	0.0	92.0	82.0
	en	40.0	89.0	88.0
	es	21.0	96.0	93.0
	fr	13.0	98.0	97.0
	ja	0.0	99.0	92.0
	zh	7.0	95.0	86.0
Llama2-7B	de	0.0	24.0	31.0
	en	89.0	99.0	99.0
	es	1.0	33.0	20.0
	fr	2.0	9.0	6.0
	ja	1.0	10.0	18.0
	zh	0.0	56.0	67.0

各言語の出力割合(% , n = 100)

実験2：ドメイン固有ニューロンの特定と比較

目的: ドメイン(分野)に関する固有ニューロンの特定および言語固有ニューロンとの比較

ドメイン: $L_{\text{domain}} = \{\text{biology(生物学)}, \text{history(歴史学)}, \text{law(法律学)},$
 $\text{mathematics(数学)}, \text{physics(物理学)}, \text{psychology(心理学)}\}$

データセット: MMLU (Hendrycks et al., 2020) より各ドメインに対して500文ずつ


ドメイン固有ニューロンの集合 $M_{l_t}^{\text{domain}}, M_{l_t}^{\text{domain}_s}$ ($l_t \in L_{\text{domain}}$) を取得し、言語固有ニューロンと比較

$M_{l_t}^{\text{domain}}$: 通常データセット

$M_{l_t}^{\text{domain}_s}$: 各文のトークンをランダムにシャッフル

結果2.1: ドメイン固有ニューロンの層分布

- ・ 言語の場合と異なり、中盤層～終盤層に多く分布
序盤層の分布数が減少
- ・ シャッフル前後で層分布の傾向は大きく変わらず



固有ニューロンの層ごとの分布(ドメインごとの平均)

(横軸: 層番号 / 縦軸: ニューロン数)

結果2.2: シャッフル前後の重複

	biology	history	law	mathematics	physics	psychology
XGLM-564M	58.15	57.20	41.30	52.10	61.75	56.05
BLOOM-1.7B	65.55	51.45	34.95	51.55	64.90	61.00
Llama-2-7B	48.35	38.50	31.25	38.40	52.70	49.05

$M_{l_t}^{\text{domain}}$ と $M_{l_t}^{\text{domain}_s}$ の重複割合(%)

	Language	Domain
XGLM-564M	76.69	54.43
BLOOM-1.7B	72.17	54.90
Llama-2-7B	48.89	43.04

言語/ドメインごとの平均重複割合(%)

(左図) 多くのモデル/ドメインで半数以上のニューロンがシャッフルする前後で重複

(右図) 一方で、いずれのモデルでも平均の重複割合は言語の場合の方が大きい

結果2.3: シャッフル前後の層ごとの重複


言語: 重複割合の偏りが少ない

ドメイン: 中盤層以降で重複割合が小さくなる傾向


総じて、**ドメイン固有ニューロン**の方が語順依存性が高い

文脈や意味的な情報の処理により強く関与していると考察


XGLM-564M



BLOOM-1.7B



Llama2-7B



シャッフル前後の固有ニューロンの層ごとの重複

(横軸: 層番号 / 縦軸: 重複割合)

実験1: 言語固有ニューロンの語順依存性の解析

- ・シャッフルする前後の言語固有ニューロンはいずれも序盤/終盤層に偏って分布し、その大部分が重複
- ・シャッフル後の固有ニューロンの出力を制御しても、各言語の生成割合は低下せず

→ **言語固有ニューロンは語順依存性が低い**

言語特有のトークンなど、文脈的情報を持たない特徴に反応していると考察

実験2: ドメイン固有ニューロンの特定

- ・言語の場合と層分布が変化し、中盤層の固有ニューロン数が増加
- ・シャッフルする前後で層分布の傾向は変化しなかったが、重複割合は言語の場合から減少

→ **ドメイン固有ニューロンは、言語固有ニューロンと比較して語順依存性が高い**

文脈情報の処理や推論により強く関与していると考察

課題

- ・現状の手法は、単一のカテゴリの文に**相対的に**強く反応するニューロンを特定する
 - 多くのカテゴリ集合に対する固有ニューロン同士を比較するには、データセットの選定が難しい
- ・ニューロンの出力の文平均を用いているため、
フレーズや文法構造など局所的な特徴を捉えるニューロンを特定できない

今後の展望

- ・データセット選定方法の精査
- ・トークンごとの出力に注目する手法の確立
- 単一の言語機能に特化したニューロン群を特定する手法として一般化し、
LLMの言語能力を細分化して解釈・理解することに寄与

- [1] Kojima, Okumura et al., “On the Multilingual Ability of Decoder-based Pre-trained Language Models: Finding and Controlling Language-Specific Neurons”, *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, 2024.
- [2] Wendler, Veselovsky et al., “Do Llamas Work in English? On the Latent Language of Multilingual Transformers”, *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2024.
- [3] Yang, Zhang et al., “PAWS-X: Cross-lingual Adversarial Dataset for Paraphrase Identification”, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 2019.
- [4] Hendrycks, Dan, et al. "Measuring massive multitask language understanding."
arXiv preprint arXiv:2009.03300, 2020.
- [5] Armand Joulin, Edouard Grave, Piotr Bojanowski, and Tomáš Mikolov.
“Bag of tricks for efficient text classification”.
In Proceedings of the 15th conference of the European chapter of the association for computational linguistics: volume 2, short papers, pages 427–431, 2017.