

モンテカルロ木探索を用いた強化学習による 抗がん剤第I相臨床試験デザイン

統計知能分野

修士課程2年 知念俊之介

修士論文発表会

研究背景

抗がん剤の治験

第Ⅰ相試験から第Ⅲ相試験までに分かれ、それぞれに様々な試験実施方法が提案されている

本研究のスコープ

第Ⅰ相試験

- ・ 後続試験で用いる用量を決定

第Ⅱ相試験


薬効の評価など

第Ⅲ層試験

標準医療との比較など

第I相試験では後続試験の投与実験で使用する用量を決定する
＝毒性が許容範囲内に収まる最大用量である「最大耐用量」の推定

- ・投薬による重度の毒性を「用量制限毒性」という
- ・許容できる用量制限毒性発生確率の上限を「標的毒性発現水準」という
- ・標的毒性発現水準に最も近い確率で用量制限毒性が発生する用量が「最大耐用量」



第I相試験では少数の被験者ごとに投与実験を繰り返していく

1. 投与用量の候補を離散的なものに固定しておく
2. 10~30人程度の総被験者を1~5人程度の「コホート」に分ける
3. 最低用量を初めのコホートに投与する
4. 前コホートの結果から、次コホートの用量を決定
(ただし、増量・減量は1段階まで)
5. 最大耐用量を推定する

繰り返す

この部分を(試験)デザインと呼ぶ

本研究

モンテカルロ木探索と強化学習でデザインを学習

ルールベースなもの，ベイズ統計学に基づくデザイン，近年提案された深層強化学習によるデザインなどがある

伝統的なデザイン

- ・ ルールベースの3例コホートデザイン[Cater+1972]
- ・ ベイズ統計学に基づくCRM[O'Quigley+1990]

深層強化学習によるデザイン

- ・ PPOアルゴリズムによるRLE[Matsuura+2023]

最大耐用量推定精度は高いものの，用量制限毒性を示す被験者が多いという安全上の課題がある

本研究の 目的

モンテカルロ木探索と強化学習を組み合わせたデザインで

1. 最大耐用量推定精度のさらなる向上
2. 安全性に関する制約の組み込み

強化学習

- ・ マルコフ性をもつ確率システムの最適制御
- ・ 各時刻 t における報酬 r_t の期待割引報酬和 $\mathbb{E}^\pi \left[\lim_{T \rightarrow \infty} \sum_{t=0}^T \gamma^t r_t \right]$ を最大化

モンテカルロ木探索

- ・ モンテカルロ・シミュレーションによる決定時プランニング手法
- ・ 数ステップ先の「先読み」により最適行動を探索

—— 提案手法で用いるアルゴリズム ——

モンテカルロ木探索を用いた強化学習[Silver+2017]

- ・ 各時刻モンテカルロ木探索を行い、その方策に近づくように学習

利点

1. 「先読み」をした行動選択で局所最適解にスタックしにくい
2. 一般的な深層強化学習では学習の難しい、非連続的な方策も獲得しやすい

提案手法

強化学習としての定式化は既存研究RLEと同様なものを用いる

状態 … これまでの投薬結果の統計量など

- 前コホートに投与した用量水準
- それぞれの用量水準にこれまで割り当てた被験者の数
- それぞれの用量水準での用量制限毒性発現者数 など

行動 … 投薬用量の増減や最大耐用量の推定

- 用量増量
- 用量維持
- 用量減量
- 最大耐用量を推定して (早期) 終了

報酬

試験終了時に最大耐用量を正しく推定できれば 1, そうでなければ -1

既存手法RLEの問題点

1. 試験が常に早期終了可能であることに起因する，**局所最適解へのスタック**が発生する可能性がある
2. 用量制限毒性が発現する被験者が多く，**安全性に関して実用上の課題がある**

モンテカルロ木探索による強化学習の利点

1. 「先読み」により，**局所最適解にスタックしにくい**
2. 非連続的方策を獲得しやすいため，**複雑な環境でも方策を学習しやすい**

提案手法で
期待されること

1. **最大耐用量推定精度の向上**
2. **安全性に関する制約を付加した，より複雑な環境でもデザインを学習できる**

提案手法のモンテカルロ木探索では、現在の「状態」（投薬結果）から得られる統計情報を利用してモンテカルロシミュレーションを行う

[Silver+2017]が導入したモンテカルロ木探索+強化学習の手法は状態の決定的遷移を仮定
▶シミュレーション軌道のランダム性は方策に起因するもののみ

確率的状态遷移への拡張による変化

1. シミュレーション軌道の状態遷移が確率的に変動
・遷移のランダム性を方策の一部と考える学習？
2. 同じ行動に対する報酬が確率的変動
・サンプリングによる値を使用？

提案手法

1. 状態遷移は事後予測分布に従う

$$s' = p(s'|s, a) = \int p(s'|\theta, s, a)p(\theta, s, a)d\theta$$

2. 報酬には事後予測期待値を利用する

$$q = \mathbb{E}[r|s, a] = \int rp(r|\theta, s, a)p(\theta|s, a)d\theta$$

アルゴリズム 1 提案手法におけるモンテカルロ木探索

```
procedure MCTS( $s_0$ )
  while MCTS 継続条件を満たす do
     $v_0 \leftarrow s_0$  に対応するノード
     $v_{\text{leaf}}, q \leftarrow \text{SELECT}(v_0)$ 
    BACKPROPAGATE( $v_{\text{leaf}}, q$ )
  return  $\arg \max_a N(s_0, a)$ 

procedure BACKPROPAGATE( $v, q$ )
  while  $v$  が親ノードを持つ do
     $Q(v) \leftarrow \frac{Q(v)N(v) + q}{N(v) + 1}$ 
     $N(v) \leftarrow N(v) + 1$ 
     $v \leftarrow v$  の親ノード

procedure SELECT( $v$ )
  while  $v$  が葉ノードでない do
     $s \leftarrow v$  に対応する状態
     $a \leftarrow \arg \max_a Q(s, a) + c_{\text{puct}} \pi_{\theta}(s, a) \frac{\sqrt{\sum_b N(s, b)}}{1 + N(s, a)}$ 
     $v' \leftarrow (s, a)$  に対応するノード
    if  $v'$  が  $v$  の子ノードでない then
       $v'$  を  $v$  の子ノードに加える
     $\psi \sim p(\psi|s)$ 
     $s' \sim p(s'|s, a, \psi)$ 
     $v'' \leftarrow s'$  に対応するノード
    if  $v''$  が  $v'$  の子ノードでない then
       $v''$  を  $v'$  の子ノードに加える
     $v \leftarrow v''$ 
   $s_{\text{leaf}} \leftarrow v$  に対応する状態
  if  $s_{\text{leaf}}$  が終了状態 then
     $a \leftarrow v$  の親ノードに対応する状態行動対  $(s, a)$  の行動  $a$ 
     $q \leftarrow \mathbb{E}[r|s_{\text{leaf}}, a] = \int (2 \times \mathbb{1}[\text{MTD}(\psi) = d_i] - 1) \frac{p(s|\psi)p(\psi)}{\int p(s|\psi')p(\psi')d\psi'} d\psi$ 
  else
     $q \leftarrow V_{\theta}(s_{\text{leaf}})$ 
  return  $v, q$ 
```

実験

Matsuuraら(2023)が行ったものと同じ設定のシミュレーション実験を行った

第Ⅰ 相試験設定

用量水準数 6


標的毒性発現水準 0.25

総被験者数 36

コホートサイズ 3

学習する環境

試験開始時に20シナリオ*からランダムにサンプルし，そのシナリオに従って状態遷移する



*用量と用量制限毒性発生確率の関係曲線のこと

提案手法は既存手法RLEより精度が約0.73%向上し，57.73%となった

最大耐用量推定精度 (%)

RLE (既存手法)

提案手法

56.99±0.11



57.73±0.11

+0.73%

第Ⅰ相試験は非常に少ない被験者で最大耐用量推定を行わなければならないため，0.73%の精度の向上は**十分意義のある結果**

参考 Zhouら(2018)の行ったシミュレーション実験における，他手法の推定精度

mTPI

CRM

BOIN

Keyboard

48.2



+1.3%

49.5



+0.8%

50.3



+0.2%

50.5

RLEの問題点

RLEは**用量制限毒性発現者**が他手法と比べて多い傾向にある



安全性に関する制約を追加

- ・ 用量制限毒性発現者の上限を設定
- ・ 人数が上限を超えるとペナルティとして負の報酬を与える

期待されるデザインの性質

最大耐用量推定においてペナルティ分以上の効用がない限り， 用量制限毒性発現者数を上限以下に抑制


実験

用量制限毒性発現者の上限値は固定，上限値を超えた際のペナルティの大きさを変えて10通りの実験を実施

結果

提案手法は，同等程度の用量制限毒性上限超過率に対して，既存手法RLEより**1%程度推定精度が高かった**

用量制限毒性発現者を同等の割合で上限以下に抑えつつ，**1%程度高い精度で最大耐用量を推定できた**



提案手法は安全性に関する制約のもとで，より優れたデザインを学習できた


まとめ

- ・ モンテカルロ木探索による強化学習を用いた，治験第Ⅰ相試験デザインを提案した
- ・ 提案手法が既存手法よりも高い最大耐用量推定精度が得られることを実験的に確認した
- ・ さらに，安全性に関する制約を付加した設定においても既存手法より優れたデザインを得られることを実験で確かめた

展望

- ・ 試験中の用量制限毒性発現者数だけでなく，他の性質もコントロールできるデザインを提案手法でうまく学習できるか実験にて確認する
 - ・ 標的毒性発現水準より大きい用量水準の投与回数
 - ・ （早期）終了までに投薬される被験者数 … など

1. Cater, S. K. (1972). Study design principles for clinical evaluation of new drugs as developed by the chemotherapy program of the National Cancer Institute. The design of clinical trials in cancer therapy, 242-289.
2. O'Quigley, J., Pepe, M., & Fisher, L. (1990). Continual reassessment method: a practical design for phase 1 clinical trials in cancer. *Biometrics*, 33-48.
3. Matsuura, K., Sakamaki, K., Honda, J., & Sozu, T. (2023). Optimal dose escalation methods using deep reinforcement learning in phase I oncology trials. *Journal of biopharmaceutical statistics*, 1-14.
4. Silver, D., Schrittwieser, J., Simonyan, K., Antonoglou, I., Huang, A., Guez, A., ... & Hassabis, D. (2017). Mastering the game of go without human knowledge. *nature*, 550(7676), 354-359.
5. Zhou, H., Murray, T. A., Pan, H., & Yuan, Y. (2018). Comparative review of novel model - assisted designs for phase I clinical trials. *Statistics in Medicine*, 37(14), 2208-2222.




ノード選択： 葉ノードに到達するまで各ノードに保存してある統計量を用いたなんらかのスコアに従って子ノードを選択し，遷移していく

ノード展開： 葉ノードの訪問回数が一定回数以上なら，葉ノードに子ノードを追加し，木を拡張する

葉ノード評価： 葉ノードから終了状態までシミュレーションを行い，報酬を得る


バックプロパゲーション： 葉ノードからのシミュレーション結果をもとに，祖先ノードに保存する統計量を更新する

Appendix 提案手法におけるモンテカルロ木探索 20



$$a = \operatorname{argmax}_a \left\{ Q(s, a) + c_{\text{puct}} \pi_{\theta}(s, a) \frac{\sqrt{\sum_b N(s, b)}}{1 + N(s, a)} \right\}$$

AlphaGo Zero[4]が用いているものと同じスコア



シナリオを ψ としたときの, 状態と行動を与えた下での事後分布

$$s' \sim p(s'|s, a) = \int p(s'|\psi, s, a) p(\psi|s) d\psi$$